Московский государственный университет имени М.В. Ломоносова
Факультет вычислительной математики и кибернетики
Кафедра математической статистики

Якунин Владимир Петрович

Поиск оптимального критерия остановки итеративной процедуры

Finding the optimal stopping criterion for an iterative procedure

Выпускная квалификационная работа

Научный руководитель:
Хохлов Юрий Степанович, профессор, д. ф-м. н.

Москва, 2026

Аннотация

В работе рассматривается задача выбора числа внутренних вычислительных шагов в малой рекурсивной языковой модели [16]. Основная прикладная задача состоит в предсказании следующей языковой единицы по уже наблюденному префиксу. Число внутренних уточнений не задаётся заранее одинаково для всех позиций, а рассматривается как объект статистического моделирования. Для каждой позиции текста по последовательности потерь определяется оракульное время остановки, минимизирующее сумму ошибки прогноза и штрафа за вычисления. Основная модель оценивает условное распределение этого оракульного времени по информации, доступной на текущем внутреннем шаге. Правило остановки строится как отдельная надстройка над полученным распределением. Описаны вероятностная модель речи, побочная постановка ARC-AGI, шесть параметрических семейств для распределения времени остановки, пять правил остановки, схема переиспользования малых языковых моделей. Приведены результаты на WikiText-103 и на контрольной выборке ARC-AGI после перебора по решётке: таблицы лучших правил остановки, эмпирическое распределение оракульного момента остановки, сравнение базового обучения и дополнительного обучения только головы оракула.

Содержание

Содержание **2**

1 Введение **4**
1.1 Актуальность темы 5
1.2 Обзор литературы 5
1.3 Цель работы 5
1.4 Научная новизна 6
1.5 Объект, предмет и метод исследования 7
1.6 Научная и практическая значимость 7

2 Постановка задачи **8**
2.1 Языковая последовательность 8
2.2 Внутреннее состояние и доступная информация 8
2.3 Потери и оракульное время остановки 9
2.4 Основная задача предсказания распределения 10

3 Вероятностная модель ARC-AGI **11**
3.1 Решетки и скрытое правило 11
3.2 Роль побочной задачи 12

4 Архитектура моделей **13**
4.1 Tiny Recursive Model с разметкой оракула 13
4.2 sLLM перед рекурсивным ядром 16

5 Рекурсивная модель и переиспользование малых языковых моделей **19**
5.1 Сравнение с LoRA 19
5.2 Переиспользование весов готовой модели 20

6 Модели распределения времени остановки **21**
6.1 Конечное дискретное распределение 21
6.2 Сглаженная целевая разметка 21
6.3 Смесь геометрических распределений 22
6.4 Дискретизированная смесь экспоненциальных распределений 22
6.5 Степенной спад на конечном отрезке 22
6.6 Отрицательное биномиальное (тяжелый хвост) 23
6.7 Сравнение семейств 23

7 Правила остановки **25**
7.1 Общий вид 25
7.2 Правило накопленной вероятности 25
7.3 Правило малой вероятности будущего улучшения 25
7.4 Правило условной интенсивности 26
7.5 Правило квантиля 26
7.6 Бюджетное правило 26

8 Обучение и оценка качества **28**
8.1 Обучающая разметка 28
8.2 Качество языкового прогноза 28
8.3 Качество предсказания времени 28
8.4 Вычислительная стоимость 29

9 Экспериментальный план и постановка замеров **30**
9.1 Языковые данные (иллюстративная конфигурация) 30
9.2 Сравниваемые варианты 31
9.3 Исследование вклада компонентов 31
9.4 Реализованный пайплайн ARC-AGI 32

10 Результаты языкового моделирования на WikiText-103 **33**
10.1 Эмпирическое распределение оракульного $\tau^\star$ 33
10.2 Сводка по семействам распределений (базовое обучение) . . 33
10.3 Влияние дополнительного обучения только головы оракула . 34
10.4 Кривая качество–стоимость 35

11 Результаты на ARC-AGI **36**
11.1 Эмпирическое распределение оракульного $\tau^\star$ 36
11.2 Сводка по семействам распределений (базовое обучение) . . 36
11.3 Влияние дополнительного обучения только головы оракула . 37
11.4 Кривая качество–стоимость 38

12 Обсуждение **40**
12.1 Интерпретация свода ARC-AGI 40
12.2 Дополнительное обучение только головы оракула и сдвиг распределений 40
12.3 Связь с постановкой математической статистики 41

13 Заключение **42**

1 Введение

Современные языковые модели строят распределение следующей языковой единицы по уже наблюденному префиксу. В обычной схеме вычислительная глубина фиксирована: для каждой позиции текста выполняется одно и то же число преобразований. Такая схема проста, но не учитывает неоднородность языковых контекстов. В одних позициях продолжение почти однозначно: после устойчивого словосочетания или синтаксически жесткой конструкции дополнительные вычисления мало меняют распределение. В других позициях полезная информация извлекается только после нескольких внутренних уточнений, поскольку требуется согласовать дальний контекст, смысловую связь и грамматические ограничения.

Эта работа рассматривает число внутренних уточнений как случайную величину, зависящую от текста и состояния модели. Практический вопрос формулируется так: когда следует остановить рекурсивное уточнение и выдать текущее распределение следующей языковой единицы?

Исходная рекурсивная идея мотивирована малыми рекурсивными моделями [16]: один и тот же или близкий по параметрам оператор несколько раз применяет уточнение к скрытому состоянию; в указанной работе основные иллюстрации даны на судоку и задачах абстрактного вывода, тогда как в настоящей работе основным объектом исследования является языковое прогнозирование. В качестве дополнительной задачи рассматривалось прогнозирование ответов на логически сложные пазлы ARC-AGI [1]: для их решения, как правило, требуется большая глубина вычислений, а в малой рекурсивной архитектуре эта глубина создаётся за счёт последовательного уточнения скрытого состояния.

Данную задачу можно разделить на две. Первая задача — вероятностная: по информации, доступной на текущем внутреннем шаге, оценить распределение оракульного времени остановки. Вторая задача — решающая: по этому распределению выбрать момент, когда вычисления следует прекратить. Такое разделение устраняет путаницу между статистическим прогнозом и правилом действия. Оно также допускает случай, когда модель считает, что лучший момент уже был в прошлом; эта информация не теряется, а учитывается правилом остановки.

1.1 Актуальность темы

Рост вычислительных затрат современных языковых моделей и практика их сжатия, адаптации и раннего выхода делают актуальным статистически корректный учет неопределенности в числе внутренних шагов. Постановка в терминах условного распределения оракульного времени остановки согласуется с классической теорией последовательных решений [28, 30] и с современными работами по адаптивной глубине сетей [12, 9].

1.2 Обзор литературы

Основы последовательного анализа и оптимальной остановки изложены, в том числе, в монографиях и статьях [28, 23, 22, 30, 20]; динамическое программирование и управление марковскими процессами обсуждаются в [14, 3]. Статистическая теория решений задаёт язык для отделения оценки риска от выбора действия [10]; родственные последовательные постановки принятия решений встречаются и в обучении с подкреплением [25]. Обучение распределений в глубоких моделях и их вероятностная интерпретация систематически описаны в [11, 4]; для последовательностей ключевым остаются рекуррентные кодировочно–декодировочные схемы и механизмы внимания [13, 19, 2, 24, 27, 8], а также масштабные предобученные языковые модели [7, 21, 5]. На практике стохастическая оптимизация параметров почти всегда опирается на адаптивные методы первого порядка [17]. Экономию вычислений без полного прохода по глубине исследуют идеи раннего выхода и адаптивной глубины [12, 9, 26, 29]; параметрическая адаптация больших представлений облегчается низкоранговым дообучением [15]. Задачи, близкие по духу к ARC-AGI, обсуждаются в [6, 1]. Для связи иллюстративного языкового плана экспериментов с открытыми корпусами удобно ориентироваться на описание WikiText-103 [18]. Компактные рекурсивные модели последовательного уточнения представления рассмотрены в [16].

1.3 Цель работы

Цель работы — построить связную вероятностную постановку выбора времени остановки при рекурсивном прогнозировании речи и описать экспериментальную схему, позволяющую сравнивать модели времени остановки по качеству прогноза и вычислительной стоимости.

Для достижения этой цели решаются следующие задачи.

1. Описать речь как случайную последовательность на конечном словаре и задать потери предсказания следующей языковой единицы.
2. Ввести рекурсивный процесс уточнения распределения и связанную с ним фильтрацию внутренней информации.
3. Определить оракульное время остановки через сумму ошибки и штрафа за вычисления.
4. Сформулировать задачу предсказания условного распределения оракульного времени остановки.
5. Выбрать ограниченный набор из шести семейств распределений на $\{0, \ldots, K\}$, пригодных для описания ранней, поздней и тяжелохвостой остановки.
6. Задать пять простых правил остановки, строящихся поверх предсказанного распределения [10, 4].
7. Описать, как переиспользовать малую предобученную языковую модель, чтобы не обучать всю систему с нуля.
8. Провести эксперименты на ARC-AGI: серию прогонов по семействам распределений, оценку правил остановки на контрольной выборке, сравнение базового обучения и дополнительного обучения только головы оракула.

1.4 Научная новизна

Научная новизна прежде всего в том, что в качестве объекта статистики рассматривается именно условное распределение $\tau^\star$ на $\{0, \ldots, K\}$: оценивается полный условный закон оракульного момента остановки по внутренней информации текущего шага, а не сводится к одному допустимому числу шагов или одноступенчатой метрике уверенности. На этой основе возможно связать прогноз распределения с решающей процедурой остановки, использующей не только вариант «остановиться сейчас», но и массы на прошлых и будущих шагах; при желании такую связь можно оформить как явную декомпозицию задачи прогноза полного закона $\tau^\star$ и задачи выбора момента остановки по этому прогнозу. Такая постановка ближе к байесовским и минимаксным схемам принятия решений [10], чем к одноступенчатым эвристикам уверенности.

1.5 Объект, предмет и метод исследования

Объект исследования — рекурсивная языковая модель, которая для одной позиции текста строит несколько последовательных приближений распределения следующей языковой единицы. Предмет исследования — распределение времени остановки этого внутреннего процесса и правила выбора момента остановки по текущей информации.

Метод исследования является комбинированным. Теоретическая часть задает вероятностную модель и функции риска. Экспериментальная часть сравнивает семейства распределений и правила остановки на языковой задаче, а также на побочной задаче ARC-AGI.

1.6 Научная и практическая значимость

Научная значимость работы состоит в том, что адаптивные вычисления переводятся в явную статистическую форму: в противоположность распространённым рецептам раннего выхода в компактных рекурсивных моделях по подходу [16] и в схемах адаптивной глубины для рекуррентных сетей и сетей на основе механизма внимания [12, 9], где критерий остановки, как правило, задаётся эвристикой уверенности или фиксированным расписанием без полного вероятностного описания момента остановки, здесь в явном виде рассматривается условное распределение оракульного времени остановки. Это позволяет анализировать не только среднее число шагов, но и форму распределения: наличие ранней массы, длинного хвоста, нескольких режимов сложности и систематического смещения правила остановки.

Практическая значимость связана с уменьшением вычислительной стоимости языкового прогноза. Если часть позиций можно надежно остановить рано, то среднее число внутренних шагов уменьшается без сильного ухудшения качества. Для малых моделей это особенно важно: дополнительная рекурсия может повышать выразительность, но ее цена должна контролироваться. В работе поэтому отдельно рассматривается переиспользование предобученной малой языковой модели и дополнительное обучение только сравнительно небольших добавочных частей.

2 Постановка задачи

2.1 Языковая последовательность

Пусть $(\Omega, \mathcal{F}, \mathsf{P})$ — вероятностное пространство. Речь задается последовательностью

$$X_1, X_2, \ldots, X_T, \qquad X_t \in \mathcal{A}, \tag{1}$$

где $\mathcal{A} = \{1, \ldots, V\}$ — конечный словарь языковых единиц. Наблюденный префикс до позиции t задает σ-алгебру

$$\mathcal{F}_t^X = \sigma(X_1, \ldots, X_t). \tag{2}$$

Истинный условный закон следующей единицы имеет вид

$$p_t(a) = \mathsf{P}(X_{t+1} = a \mid \mathcal{F}_t^X), \qquad a \in \mathcal{A}. \tag{3}$$

Этот закон неизвестен и оценивается моделью.

В рекурсивной схеме для каждой позиции t строится не одно, а несколько приближений к p_t:

$$Q_{t,0}, Q_{t,1}, \ldots, Q_{t,K}, \qquad Q_{t,k} \in \Delta^{V-1}. \tag{4}$$

Здесь $k = 0$ обозначает начальное распределение, а $k = 1, \ldots, K$ — результаты внутренних уточнений. Для фиксированной позиции можно остановиться на любом шаге от 0 до K.

2.2 Внутреннее состояние и доступная информация

Рекурсивная модель хранит скрытое состояние $Z_{t,k}$. Начальное состояние строится по префиксу:

$$Z_{t,0} = E_\phi(X_1, \ldots, X_t), \tag{5}$$

где E_ϕ — исходный языковой преобразователь. Далее применяется оператор уточнения

$$Z_{t,k+1} = U_\theta(Z_{t,k}, C_t, Q_{t,k}), \qquad k = 0, \ldots, K-1. \tag{6}$$

Величина C_t обозначает представление контекста, которое не меняется внутри рекурсивного цикла или меняется медленнее, чем $Z_{t,k}$. После каждого шага скрытое состояние переводится в распределение на словаре:

$$Q_{t,k}(a) = \frac{\exp s_{t,k}(a)}{\sum_{b \in \mathcal{A}} \exp s_{t,k}(b)}, \qquad a \in \mathcal{A}. \tag{7}$$

Информация, доступная к внутреннему шагу k, задается как

$$\mathcal{H}_{t,k} = \mathcal{F}_t^X \vee \sigma(Z_{t,0}, Q_{t,0}, \ldots, Z_{t,k}, Q_{t,k}, S_{t,0}, \ldots, S_{t,k}), \tag{8}$$

где $S_{t,k}$ — вектор вычисляемых статистик. В него можно включить энтропию распределения, отрыв первой вероятности от второй, изменение распределения между соседними шагами и норму изменения скрытого состояния. Эти статистики не вводят новую сущность задачи: они являются функциями уже построенных $Z_{t,k}$ и $Q_{t,k}$.

2.3 Потери и оракульное время остановки

После того как известна истинная следующая языковая единица X_{t+1}, потери при остановке на шаге k определяются как

$$L_{t,k} = -\log Q_{t,k}(X_{t+1}). \tag{9}$$

Если учитывается не только качество прогноза, но и стоимость вычислений, вводится функция стоимости $c(k)$. В простейшем случае $c(k) = k$. Оракульное время остановки равно

$$\tau_t^\star = \arg\min_{0 \le j \le K} \{L_{t,j} + \lambda c(j)\}, \tag{10}$$

где $\lambda \ge 0$ — коэффициент цены вычислений. При равенстве нескольких минимумов выбирается наименьший j, поскольку более ранняя остановка имеет ту же ошибку при меньшей или равной стоимости.

Оракульное время не является реализуемым правилом вывода: для его вычисления требуется знать все будущие внутренние шаги и истинный ответ. Оно используется как обучающая целевая величина и как статистический объект анализа.

2.4 Основная задача предсказания распределения

На шаге k модель времени остановки должна выдать условное распределение

$$\widehat{p}_{t,k}(j) = \mathsf{P}_\theta(\tau_t^\star = j \mid \mathcal{H}_{t,k}), \qquad j = 0, \ldots, K, \tag{11}$$

Для пакета размера B, длины последовательности T и $K+1$ возможных шагов выход имеет размер

$$B \times T \times (K+1) \times (K+1). \tag{12}$$

Третья ось соответствует текущему шагу k, четвертая — возможному значению оракульного времени j.

В (11) символ P_θ обозначает вероятностную меру, задаваемую параметрической моделью с параметром θ (обучаемым вектором весов): $\widehat{p}_{t,k}(j)$ — $\mathcal{H}_{t,k}$-измеримая вероятность на $\{0, \ldots, K\}$. Истинное условное распределение $\tau_t^\star$ по $\mathcal{H}_{t,k}$ относительно исходной меры P в общем случае неизвестно и не совпадает с P_θ. Событие $\{\tau_t^\star = j\} \subset \Omega$ задается после наблюдения X_{t+1} и полной траектории внутренних прогнозов, достаточной для вычисления (10).

Эта постановка принципиально отличается от прямого прогнозирования только индикатора $\{\tau_t^\star = k\}$ без учета масс на $\{\tau_t^\star < k\}$ и $\{\tau_t^\star > k\}$. Модель сохраняет информацию о трех ситуациях:

$$P_{t,k}^{\text{past}} = \sum_{j<k} \widehat{p}_{t,k}(j), \tag{13}$$

$$P_{t,k}^{\text{now}} = \widehat{p}_{t,k}(k), \tag{14}$$

$$P_{t,k}^{\text{future}} = \sum_{j>k} \widehat{p}_{t,k}(j). \tag{15}$$

Первая величина показывает вероятность того, что лучший момент уже был пропущен. Вторая — вероятность того, что текущий шаг является оптимальным. Третья — вероятность того, что полезное уточнение еще впереди. Правило остановки строится поверх этих величин.

3 Вероятностная модель ARC-AGI

3.1 Решетки и скрытое правило

Побочная задача ARC-AGI [1, 6] используется не как основной источник результатов, а как проверка переносимости идеи времени остановки. В этой задаче вход представляет собой цветную решетку

$$A \in \{1, \dots, C\}^{H \times W}, \tag{16}$$

а ответ — выходную решетку

$$Y \in \{1, \dots, C\}^{H' \times W'}. \tag{17}$$

Для одной задачи предполагается скрытое правило преобразования Θ, по которому несколько обучающих пар согласованы между собой. Условно это можно записать как

$$Y = f_\Theta(A). \tag{18}$$

Рекурсивная модель в этом случае строит последовательность распределений по цветам клеток:

$$Q_k(i, j, c) = \mathsf{P}(Y_{i,j} = c \mid A, \mathcal{H}_k), \qquad c = 1, \dots, C. \tag{19}$$

Потеря всей решетки при остановке на шаге k задается суммой по клеткам:

$$L_k^{\text{arc}} = -\sum_{i,j} \log Q_k(i, j, Y_{i,j}). \tag{20}$$

Оракульное время остановки определяется так же, как в языковой задаче:

$$\tau_{\text{arc}}^\star = \operatorname*{arg\,min}_{0 \le j \le K} \{L_j^{\text{arc}} + \lambda c(j)\}. \tag{21}$$

Для ARC-AGI естественно использовать одно время остановки на всю решетку. Отдельное время для каждой клетки технически возможно, но нарушает смысл задачи: ответ оценивается как единый объект, а не как независимый набор клеток. Поэтому выход распределительной модели имеет размер

$$B \times (K + 1) \times (K + 1), \tag{22}$$

где B — число задач или примеров в пакете.

3.2 Роль побочной задачи

В языковой задаче трудность позиции может быть связана с грамматикой, частотностью словосочетания, дальними зависимостями и неоднозначностью смысла. В ARC-AGI трудность имеет другую природу: модель должна восстановить скрытое преобразование решетки. Если распределение времени остановки в двух задачах демонстрирует сходные режимы, это поддерживает гипотезу, что предсказание времени остановки описывает общую вычислительную сложность объекта, а не только частный эффект языковых данных.

4 Архитектура моделей

В этом разделе заданы параметрические блоки малой рекурсивной схемы (tiny recursive model, TRM) в связке с обучением по меткам оракульного времени остановки, а также модификация, в которой к рекурсии подключается предобученная малая языковая модель (small language model, sLLM). Смысл объектов $\tau^\star$ и последовательностей $\{Z_{t,k}\}$, $\{Q_{t,k}\}$, $\{\widehat{p}_{t,k}\}$ согласуется с разд. 2.2; здесь они конкретизируются указанием наборов обучаемых параметров.

4.1 Tiny Recursive Model с разметкой оракула

Изоморфный оператор ядра. Для каждого внутреннего шага задаётся отображение

$$\mathcal{U}_\theta : \mathbb{R}^{d_z} \times \mathbb{R}^{d_c} \times \Delta^{V-1} \to \mathbb{R}^{d_z}, \qquad Z_{t,k+1} = Z_{t,k} + \mathcal{U}_\theta(Z_{t,k}, C_t, Q_{t,k}), \quad k = 0, \ldots, K-1, \tag{23}$$

что задаёт параметрическую версию блока (6) в виде остаточного обновления; $C_t \in \mathbb{R}^{d_c}$ может быть функцией префикса и не изменяться внутри цикла.

Чистая TRM-ветка без внешней sLLM. Префикс кодируется одним параметрическим кодировщиком (эмбеддинги токенов и возможные свёрточные/транзиентные блоки малой глубины):

$$Z_{t,0} = E_{\phi^{(\mathrm{trm})}}(X_1, \ldots, X_t), \qquad \phi^{(\mathrm{trm})} \in \Phi_{\mathrm{trm}}. \tag{24}$$

Прогностическая голова. По текущей скрытой переменной строится вектор логитов и распределение на словаре:

$$s_{t,k}(a) = g_\eta(a, Z_{t,k}, C_t), \qquad a \in \mathcal{A}, \tag{25}$$

$$Q_{t,k} = \mathrm{softmax}(s_{t,k}(\cdot)), \tag{26}$$

то есть параметрическая версия связи (7); все $g_\eta(\cdot, Z_{t,k}, C_t)$ задают одну и ту же функцию $\mathbb{R}^{d_z+d_c} \to \mathbb{R}^V$ в зависимости от аргумента a (строчное матричное умножение после конкатенации признаков).

Голова времени останова. Собирается вектор признаков $\mathbf{g}_{t,k} = R_\psi(\mathbf{h}_{t,k})$, $\mathbf{h}_{t,k} = \big(Z_{t,k}, Q_{t,k}, \mathrm{diag}(Z_{t,k})\big)$ после выбора фиксированного конкатенированного или иного агрегирования статистик (как множество

$\{S_{t,k}\}$ в (8)) и задаётся

$$\widehat{p}_{t,k}(\cdot) = \mathrm{softmax}\big(W_\omega \mathbf{g}_{t,k} + b_\omega\big), \qquad (\omega) = (W_\omega, b_\omega, \psi),\ \omega \in \Omega. \tag{27}$$

Форма Π_ω, используемая в тексте экспериментов как «голова модели времени», совпадает с параметрическим семейством на $\{0, \ldots, K\}$ после фиксации размерности выходного слоя.

Разметка оракула. После вычисления всех $\{Q_{t,j}\}_{j=0}^{K}$ и наблюдения X_{t+1} по формулам (9)–(10) получают число $\tau_t^\star$. Обучение головы (27) задаётся, например, перекрестной энтропией между $\widehat{p}_{t,k}(\cdot|\omega)$ и индикатором точечной метки $\tau_t^\star$ (или сглаженной разметкой, см. 6 и (33)); прогностическое ядро и LM-голова обучаются по потере (9) на выбранных шагах. На этапе вывода оракульная разметка не используется: применяется правило (37) поверх $\widehat{p}_{t,k}$.

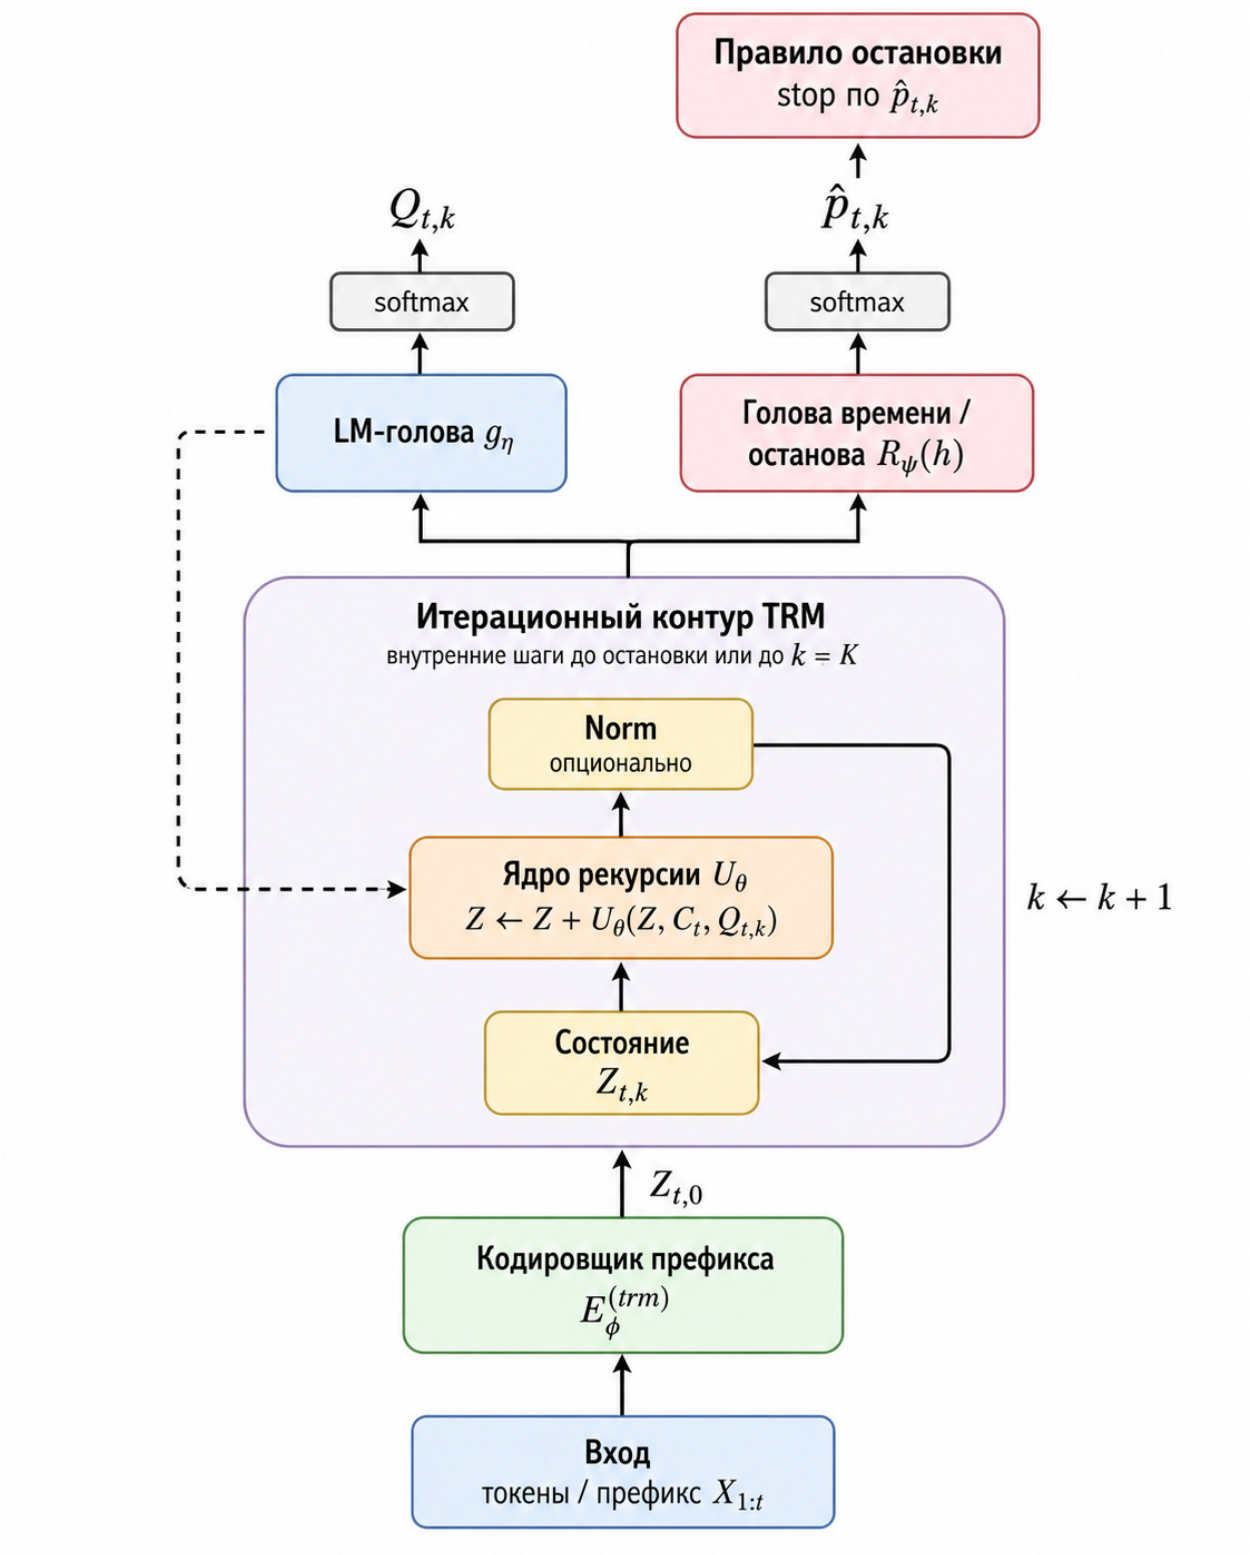

Рис. 1. Структура сети чистого TRM (без внешней sLLM): кодировщик префикса, остаточное ядро $\mathcal{U}_\theta$ с итерациями по $k \leq K$, LM-голова и голова времени, минимальное правило остановки по $\widehat{p}_{t,k}$. Разметка оракула $\tau_t^\star$ и совместное обучение блоков описаны текстом выше; на схеме показан только вычислительный граф.

Рисунок 1 согласуется с записью (23)–(27): многократные шаги по k, использование распределения $Q_{t,k}$ во входном наборе ядра $\mathcal{U}_\theta$ и

построение голов после формирования скрытого состояния.

4.2 sLLM перед рекурсивным ядром

В иной конфигурации префикс сначала пропускается через предобученную малую языковую модель, фиксирующую промежуточное представление последнего токена (или среднее по последним m позициям):

$$h_t = \mathrm{sLLM}_{\phi^{(\mathrm{s})}}(X_1, \ldots, X_t), \qquad h_t \in \mathbb{R}^{d_h}, \tag{28}$$

$$Z_{t,0} = P_\psi(h_t), \qquad P_\psi : \mathbb{R}^{d_h} \to \mathbb{R}^{d_z},\ \psi \in \Psi. \tag{29}$$

Параметры $\phi^{(\mathrm{s})}$ чаще замораживают или ограниченно корректируют; главная добавочная связь — проектор P_ψ. Дальше задаются те же (23), (26), (27), при необходимости с разделением параметров между «внешней» и чистой TRM-схемами.

Необязательный LoRA. В качестве дешёвой адаптации вместо или вместе с полным изменением $\phi^{(\mathrm{s})}$ в промежуточных линейных слоях sLLM фиксируют низкоранговые приращения коэффициентов в представлении [15]: матрицы в слоях заменяют на $W + \alpha\, B^\top A$ с малыми рангами $A \in \mathbb{R}^{r \times d_{\mathrm{in}}}$, $B \in \mathbb{R}^{r \times d_{\mathrm{out}}}$, $r \ll \min\{d_{\mathrm{in}}, d_{\mathrm{out}}\}$. Эти дополнительные параметры относятся к множеству $\Phi_{\mathrm{adapt}} \subset \Phi_{\mathrm{trm}} \cup \Psi$; обозначение *LoRA* в работе сохраняется как принятое в литературе имя метода без русского перевода.

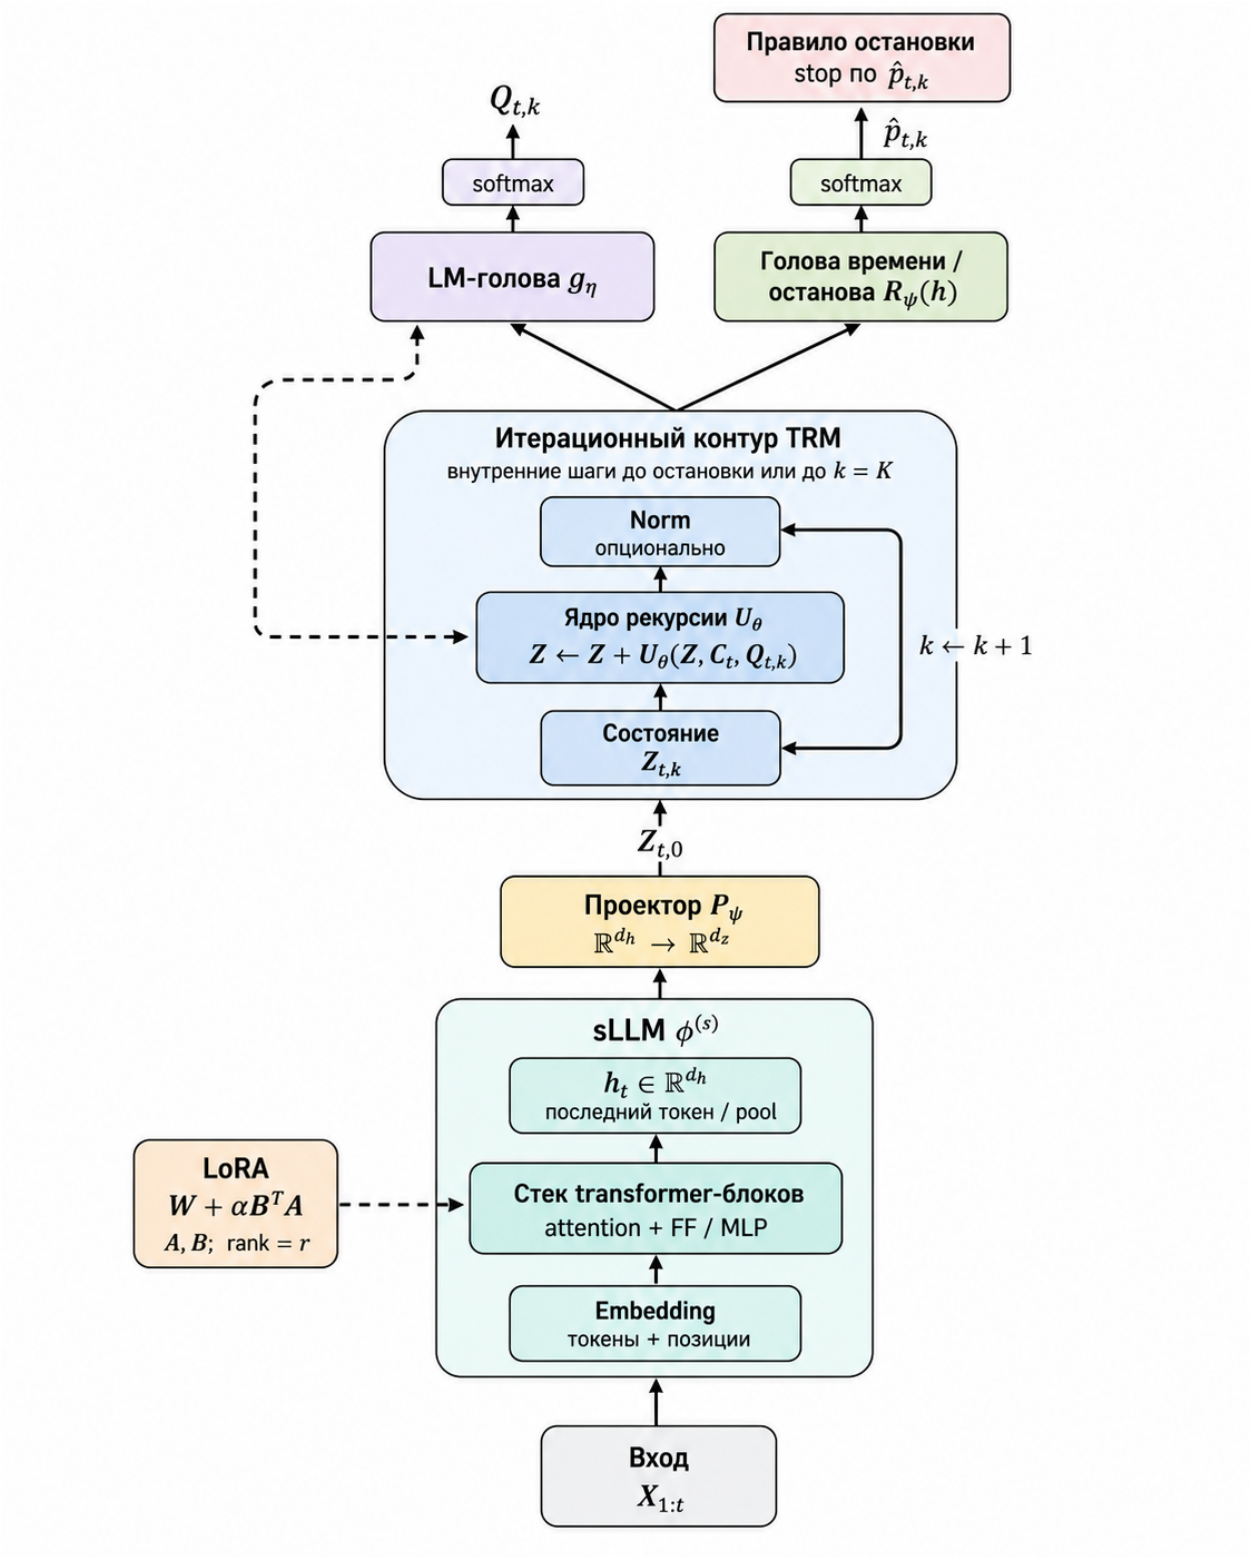

Рис. 2. Структура сети sLLM + TRM: эмбеддинг и стек трансформерных блоков (опционально с LoRA [15]) задают h_t, проектор P_ψ переводит в $Z_{t,0}$; далее — то же рекурсивное ядро и головы, что на рис. 1. Обучение по оракульной разметке описано текстом выше.

Обобщённый параметр одной сборки композиции запишется как

наложение ограничений

$$\Theta = \left(\phi^{(\mathrm{s})}, \psi, \theta, \eta, \omega, \text{ возможно члены LoRA }\right)$$

с разнесением множества обучения по задачам: ядро и головы TRM традиционно включаются в каждый градиентный шаг, параметры $\phi^{(\mathrm{s})}$ и LoRA включаются выборочно.

5 Рекурсивная модель и переиспользование малых языковых моделей

Авторская рекурсивная схема обсуждается в литературе как tiny recursive model (TRM) [16]. Последовательность внутренних состояний, распределений $Q_{t,k}$ и голов времени описана в разд. 2.2; параметризация блоков E_ϕ, оператора U_θ (в виде остаточного ядра $\mathcal{U}_\theta$) и возможная композиция с малой языковой моделью задаются формально в разд. 4. Ниже сосредоточены сравнение с методом LoRA и кратко зафиксировано переиспользование весов малой предобученной модели.

Смысл рекурсии состоит не в механическом увеличении числа слоёв поверх уже обученной сетки. Один и тот же оператор уточнения применяется к состоянию несколько раз, а число применений определяется данными через правило остановки над $\widehat{p}_{t,k}$. Поэтому модель может тратить меньше вычислений на простые позиции и больше — на сложные.

5.1 Сравнение с LoRA

Метод LoRA [15] решает типичную инженерную задачу: не переписывая большие тензоры предобученной модели, повысить её качество на целевой задаче. Базовые веса остаются фиксированными, а в выбранных линейных слоях появляется учимое низкоранговое приращение вида $\alpha B^\top A$. После обучения граф вывода остаётся обычным для трансформера: одна и та же фиксированная глубина сетки, одинаковая для всех позиций и всех предложений; меняется только сама функция, реализуемая сеткой, за счёт добавленных параметров.

Предлагаемая рекурсивная схема физически устроена иначе. Качество на позиции повышается не (или не только) за счёт перенастройки матриц внутри слоёв базы, а за счёт *политики внутреннего времени*: одно и то же ядро $\mathcal{U}_\theta$ может применяться разное число раз, а решение о продолжении или остановке принимается по головам $\widehat{p}_{t,k}$ и правилу остановки (разд. 2.2). При замороженной малой языковой модели это отдельный вычислительный контур над её представлением — проекция и рекурсия из разд. 4 — а не изменение топологии «одного прохода по трансформеру».

С практической стороны и LoRA, и рекурсия на замороженном чекпоинте отвечают на один и тот же вопрос: как выжать качество из *той*

же малой предобученной модели, доплатив сравнимо умеренным числом обучаемых параметров или модулей. Без режима «только LoRA» контраст «рекурсивная надстройка» против «замороженная база без малоранговой адаптации трансформера» остаётся неоднозначным: вклад малоранговой параметрической подгонки к данным смешался бы с вкладом переменной глубины цикла. Добавление LoRA в решётку не означает, что методы конкурируют концептуально; это явный второй базовый способ улучшить данную модель, относительно которого можно оценить, оправдана ли именно управляемая глубина.

5.2 Переиспользование весов готовой модели

Предлагается использовать TRM — проектор P_ψ, ядро $\mathcal{U}_\theta$, прогностическая и временная головы (разд. 4) — как надстройку над полностью замороженными весами малой предобученной модели Falcon-H1-Tiny порядка 90 M параметров (`tiiuae/Falcon-H1-Tiny-90M-Base`), получая признаки с её `last_hidden_state`. На том же чекпоинте для сравнения по качеству отдельно прогоняют вариант с LoRA [15] без рекурсивного контура; объединять LoRA и рекурсию в одном прогоне в данной выпускной работе не предполагается.

6 Модели распределения времени остановки

6.1 Конечное дискретное распределение

Базовый вариант — не навязывать форму распределения и напрямую оценивать вероятности всех возможных значений:

$$\widehat{p}_{t,k}(0), \ldots, \widehat{p}_{t,k}(K), \qquad \sum_{j=0}^{K} \widehat{p}_{t,k}(j) = 1. \tag{30}$$

Параметры получаются из вектора признаков $G_{t,k}$, построенного по $Z_{t,k}$, $Q_{t,k}$ и простым статистикам уверенности:

$$\widehat{p}_{t,k} = \mathrm{softmax}(AG_{t,k} + b). \tag{31}$$

Эта модель является основной отправной точкой. Она удобна при небольшом K, не требует предположений о хвосте и сразу дает вероятности прошлого, текущего и будущего оптимума.

6.2 Сглаженная целевая разметка

Оракульная метка $\tau^\star$ может быть слишком жесткой. Если два соседних шага дают почти одинаковое значение $L_{t,j} + \lambda c(j)$, то принудительный выбор одного шага увеличивает шум обучения. Поэтому вместо точечной метки можно использовать сглаженное целевое распределение

$$p_t^\star(j) = \frac{\exp\{-(L_{t,j} + \lambda c(j))/\beta\}}{\sum_{r=0}^{K} \exp\{-(L_{t,r} + \lambda c(r))/\beta\}}, \tag{32}$$

где $\beta > 0$ управляет степенью сглаживания. При малом β модель близка к точечной разметке; при большом β распределение становится мягче.

Целевая функция для конечной модели записывается как перекрестная энтропия:

$$\mathcal{L}_{\text{dist}} = -\sum_{t} \sum_{k=0}^{K} \sum_{j=0}^{K} p_t^\star(j) \log \widehat{p}_{t,k}(j). \tag{33}$$

Если используется точечная разметка, то $p_t^\star$ заменяется единичной массой в $\tau_t^\star$.

6.3 Смесь геометрических распределений

Если большинство объектов останавливается рано, а поздние остановки встречаются реже, естественным приближением является смесь геометрических распределений:

$$\widehat{p}_{t,k}(j) = \sum_{m=1}^{M} \pi_{t,k,m}(1-\rho_{t,k,m})^j \rho_{t,k,m}, \qquad j = 0, \ldots, K. \tag{34}$$

После ограничения на конечный отрезок $0, \ldots, K$ распределение нормируется. Компоненты смеси соответствуют разным режимам сложности: простые позиции имеют большую вероятность ранней остановки, сложные — более медленный спад.

Эта модель использует меньше свободных параметров, чем произвольное дискретное распределение. Она полезна как регуляризованная альтернатива, особенно при малом объеме обучающей выборки для модели времени.

6.4 Дискретизированная смесь экспоненциальных распределений

Близкая по смыслу модель получается из непрерывного времени. Для $j = 0, \ldots, K$ можно задать

$$\widehat{p}_{t,k}(j) = \sum_{m=1}^{M} \pi_{t,k,m} \left[\exp(-\alpha_{t,k,m} j) - \exp(-\alpha_{t,k,m}(j+1))\right], \tag{35}$$

с последующей нормировкой на конечном отрезке. Эта форма удобна, если время остановки трактуется как дискретизация непрерывного времени ожидания.

В работе эта модель рассматривается не как обязательное усложнение, а как один компактный способ проверить, достаточно ли простого экспоненциального хвоста для описания данных.

6.5 Степенной спад на конечном отрезке

Отдельное семейство `power` в реализации соответствует вероятностям с алгебраическим убыванием по индексу шага после нормировки на $\{0, \ldots, K\}$. Такая форма служит контрастом к экспоненциально-геометрическому спаду: она допускает относительно большую массу на умеренно больших j и используется как проверка гипотезы о “мягком” хвосте без введения второго параметра дисперсии,

как в отрицательном биномиальном законе.

6.6 Отрицательное биномиальное (тяжелый хвост)

В ряде контекстов поздние остановки могут встречаться чаще, чем предсказывает геометрическая или экспоненциальная модель. Тогда нужна тяжелохвостая форма. В качестве основной такой формы берется отрицательное биномиальное распределение:

$$\widehat{p}_{t,k}(j) = \binom{j + r_{t,k} - 1}{j} (1 - \rho_{t,k})^j \rho_{t,k}^{r_{t,k}}, \qquad j = 0, \ldots, K. \tag{36}$$

После ограничения на $0, \ldots, K$ вероятности нормируются. Эта модель гибче геометрической: она допускает большую дисперсию и лучше описывает редкие сложные случаи.

6.7 Сравнение семейств

В работе не требуется вводить больше семейств, чем необходимо для проверки основных гипотез. В экспериментах ARC-AGI используются шесть вариантов: конечное дискретное распределение, сглаженная целевая разметка, смесь геометрических распределений, дискретизированная смесь экспоненциальных распределений, степенной спад на отрезке и отрицательное биномиальное распределение. Их роли сведены в табл. 1.

Таблица 1. Семейства распределений времени остановки

Семейство	Когда полезно	Основной проверяемый эффект
Конечное дискретное	малое или среднее число шагов	форма распределения без ограничений
Сглаженная разметка	несколько близких минимумов риска	устойчивость обучения
Смесь геометрических	ранняя остановка преобладает	несколько режимов сложности
Смесь экспоненциальных	нужен компактный спад хвоста	связь с временем ожидания
Степенной спад (`power`)	хвост медленнее экспоненты	алгебраическая форма на $\{0, \ldots, K\}$
Отрицательное биномиальное	заметны поздние остановки	тяжелый хвост, два параметра формы

7 Правила остановки

7.1 Общий вид

Предсказанное распределение $\widehat{p}_{t,k}$ само по себе не является правилом действия. Правило остановки — это функция, которая на шаге k принимает решение по $\mathcal{H}_{t,k}$ и $\widehat{p}_{t,k}$. Реализуемое время остановки имеет вид

$$\tau_t = \inf\{k : \varphi_k(\widehat{p}_{t,k}, \mathcal{H}_{t,k}) = 1\}. \tag{37}$$

Если ни одно условие не выполнено, полагается $\tau_t = K$.

Ниже оставлены пять правил. Они выбраны потому, что легко реализуются, имеют ясную интерпретацию и дают разные режимы управления стоимостью.

7.2 Правило накопленной вероятности

Первое правило останавливается, когда вероятность того, что оптимальный момент уже наступил, становится достаточно высокой:

$$\sum_{j \le k} \widehat{p}_{t,k}(j) \ge c. \tag{38}$$

Порог $c \in (0,1)$ подбирается на проверочной выборке. Большой порог делает правило осторожным и увеличивает среднее число шагов. Малый порог дает более раннюю остановку.

Это правило является основным кандидатом для практического использования. Оно устойчиво к шуму в одной точке распределения и прямо учитывает случай, когда лучший момент уже прошел.

7.3 Правило малой вероятности будущего улучшения

Второе правило останавливается, когда вероятность будущего оптимума мала:

$$\sum_{j > k} \widehat{p}_{t,k}(j) \le \varepsilon. \tag{39}$$

Параметр ε задает допустимую вероятность того, что продолжение еще могло бы быть полезным. В отличие от предыдущего правила, здесь внимание направлено не на накопленную массу прошлого и настоящего, а на остаточную массу будущего.

7.4 Правило условной интенсивности

Третье правило использует дискретную условную «интенсивность» (hazard), построенную по предсказанной мере $\widehat{p}_{t,k}$, а не по неизвестному истинному закону:

$$h_{t,k} = \frac{\widehat{p}_{t,k}(k)}{\sum_{j \geq k} \widehat{p}_{t,k}(j)}. \tag{40}$$

Она совпадает с классической формулой $\mathsf{P}(\tau_t^\star = k \mid \tau_t^\star \geq k, \mathcal{H}_{t,k})$ в том специальном случае, когда $\widehat{p}_{t,k}$ совпадает с истинным условным распределением. Остановка выполняется при

$$h_{t,k} \geq c_h. \tag{41}$$

Это правило связывает распределительную постановку с классическим видом последовательного решения «остановиться или продолжить». Оно полезно как интерпретируемая производная от полной модели распределения.

7.5 Правило квантиля

Пусть $q_\alpha(t,k)$ — α-квантиль предсказанного распределения:

$$q_\alpha(t,k) = \min \left\{ r : \sum_{j \leq r} \widehat{p}_{t,k}(j) \geq \alpha \right\}. \tag{42}$$

Правило останавливается, если

$$q_\alpha(t,k) \leq k. \tag{43}$$

Квантильное правило менее чувствительно к дальнему хвосту, чем правило по математическому ожиданию. Поэтому оно удобно в экспериментах с тяжелохвостыми моделями.

7.6 Бюджетное правило

Пятое правило не задает новый функционал, а выбирает порог для одного из предыдущих правил так, чтобы выполнялось ограничение на среднее число шагов:

$$\mathsf{E}\, \tau_t \leq C. \tag{44}$$

Например, можно использовать правило накопленной вероятности и подобрать c на проверочной выборке. Это правило необходимо для

честного сравнения: две модели следует сравнивать не только при одном пороге, но и при одинаковой вычислительной стоимости.

Таблица 2. Пять правил остановки

Правило	Условие остановки	Что контролирует
Накопленная вероятность	$\sum_{j \le k} \widehat{p}_k(j) \ge c$	вероятность, что оптимум уже наступил
Малое будущее улучшение	$\sum_{j > k} \widehat{p}_k(j) \le \varepsilon$	остаточную пользу продолжения
Условная интенсивность	$\widehat{p}_k(k) / \sum_{j \ge k} \widehat{p}_k(j) \ge c_h$	текущий шаг среди не прошедших
Квантиль	$q_\alpha(k) \le k$	надёжный уровень остановки
Бюджет	$\mathsf{E}\,\tau \le C$	среднюю стоимость вычислений

8 Обучение и оценка качества

8.1 Обучающая разметка

Для каждой позиции обучающей выборки сначала выполняются все K внутренних шагов. Затем вычисляются потери $L_{t,0}, \ldots, L_{t,K}$ и оракульное время $\tau_t^\star$ по формуле (10). После этого обучается модель распределения $\widehat{p}_{t,k}$.

Если используется точечная разметка, целевая функция имеет вид

$$\mathcal{L}_{\text{point}} = -\sum_t \sum_{k=0}^{K} \log \widehat{p}_{t,k}(\tau_t^\star). \tag{45}$$

Если используется сглаженная разметка, применяется функция (33). Оба варианта нужно сравнить, поскольку точечная разметка проще, а сглаженная лучше отражает близкие по риску шаги.

8.2 Качество языкового прогноза

Основная метрика качества прогноза — средняя отрицательная логарифмическая потеря при фактическом времени остановки:

$$\overline{L} = \frac{1}{N} \sum_{t=1}^{N} -\log Q_{t,\tau_t}(X_{t+1}). \tag{46}$$

Дополнительно фиксируется доля совпадений верхнего варианта с правильной языковой единицей:

$$\text{Acc} = \frac{1}{N} \sum_{t=1}^{N} \mathbb{I}\left\{ \arg\max_{a \in \mathcal{A}} Q_{t,\tau_t}(a) = X_{t+1} \right\}. \tag{47}$$

Эти метрики нужны вместе: логарифмическая потеря чувствительна к качеству распределения, а доля совпадений показывает поведение верхнего варианта.

8.3 Качество предсказания времени

Для самой модели времени используются два показателя. Первый — отрицательная логарифмическая потеря по $\tau^\star$:

$$\text{NLL}_\tau = -\frac{1}{N(K+1)} \sum_t \sum_{k=0}^{K} \log \widehat{p}_{t,k}(\tau_t^\star). \tag{48}$$

Второй — средняя абсолютная ошибка математического ожидания:

$$\mathrm{MAE}_\tau = \frac{1}{N(K+1)} \sum_t \sum_{k=0}^{K} \left| \sum_{j=0}^{K} j \widehat{p}_{t,k}(j) - \tau_t^\star \right|. \tag{49}$$

8.4 Вычислительная стоимость

Стоимость измеряется средним числом внутренних шагов

$$\overline{\tau} = \frac{1}{N} \sum_{t=1}^{N} \tau_t \tag{50}$$

и долей экономии относительно полного запуска:

$$\mathrm{Save} = 1 - \frac{\overline{\tau}}{K}. \tag{51}$$

Если учитывается начальный шаг 0, в знаменателе можно использовать $K+1$; в экспериментах нужно зафиксировать один вариант и не менять его между таблицами.

9 Экспериментальный план и постановка замеров

9.1 Языковые данные (иллюстративная конфигурация)

Обучаемая надстройка для языковой серии задаётся конфигурациями репозитория: отдельно рекурсивный режим над замороженным Falcon и отдельно файнтюн через LoRA на том же чекпоинте (состав модулей и отсутствие совместного режима — разд. 5).

Основная серия экспериментов на естественном языке в полном объеме в данной работе не воспроизводится: ниже приведена *типовая* постановка на публично доступных корпусах, чтобы зафиксировать масштабы и используемые показатели качества. Численные значения в табл. 3 являются **ориентировочными заготовками** для масштаба величин и не должны трактоваться как результат конкретного численного эксперимента из кода проекта.

Таблица 3. Иллюстративные параметры языкового эксперимента (публичные корпуса; числа условные; параметры задаются автором только как масштаб постановки; корпус WikiText-103 — [18])

Параметр	Значение (иллюстрация)
Корпус язык моделирования	WikiText-103
Альтернатива для сравнения масштаба	OpenWebText (класс подвыборок)
Размер словаря V	50256
Длина контекста в токенах	512
Максимальное число внутренних шагов K	8
Коэффициент стоимости lambda	0.05
Размер обучающей выборки позиций	12000000
Размер проверочной выборки позиций	150000
Размер контрольной выборки позиций	150000
Число эпох и зерен	3 эпохи / 2 зерна инициализации

Для такой постановки на контрольной выборке ожидаются, например, перплексия порядка 28–32 и доля точного совпадения верхнего токена порядка $0{,}35$–$0{,}42$ при фиксированной глубине рекурсии; эти диапазоны приведены только как ориентир методологии оценки и подлежат замене фактическими значениями при подключении языкового эксперимента к тому же коду, что использован для ARC-AGI.

9.2 Сравниваемые варианты

Сравнение должно быть устроено так, чтобы не смешивать вклад разных частей. Минимальный набор вариантов приведен в табл. 4. Первая строка задает обычную модель с фиксированной глубиной. Остальные строки проверяют, что именно дает выигрыш: предобученная основа, рекурсивное уточнение, модель распределения времени или правило остановки.

Таблица 4. Сравниваемые варианты модели

Вариант	Основа	Рекурсия	Время остановки
Фиксированная глубина	малая языковая модель	нет	не используется
Полный запуск рекурсии	малая языковая модель	до K шагов	всегда K
Ранняя остановка по энтропии	малая языковая модель	до K шагов	простая эвристика
Распределение $\tau^\star$	малая языковая модель	до K шагов	одно из пяти правил
LoRA [15]	та же замороженная основа	нет (только малоранговые добавки)	не используется

9.3 Исследование вклада компонентов

Исследование вклада компонентов нужно ограничить только тем, что относится к основной гипотезе. Проверяются четыре фактора: форма распределения времени, тип разметки, правило остановки и способ переиспользования малой языковой модели. Шаблон таблицы приведен в табл. 5.

Таблица 5. Шаблон таблицы исследования вклада компонентов

Вариант	Потери	NLL,	Среднее	Экономия
	речи		число шагов	
Конечное распределение + накопленная вероятность	—	—	—	—
Сглаженная разметка + накопленная вероятность	—	—	—	—
Смесь геометрических + малое будущее улучшение	—	—	—	—
Отрицательное биномиальное + квантиль	—	—	—	—
Бюджетное правило при заданном бюджете	—	—	—	—

9.4 Реализованный пайплайн ARC-AGI

Для ARC-AGI зафиксирована серия из шести семейств распределения времени остановки. Для каждого семейства обучается рекурсивная модель с головой оракула; затем на контрольной выборке воспроизводится полная решётка правил остановки. В репозитории перечисление стратегий и порогов задано конфигурацией набора экспериментов (в коде `configs/oracle_sweep_arc_agi/`); сами стратегии имеют технические имена `cumulative_probability`, `future_improvement`, `hazard`, `quantile`, `budget`, а связка «режим формирования ответа / порог или бюджет» для каждого семейства подбирается по контрольной выборке. Режимы агрегирования кандидатов ответа фиксируются идентификаторами `last` и `argmax_interval`. По итогам серии сохраняется сводная таблица; внутри каждого семейства строка выбирается по вспомогательному критерию `token_acc_best_of_policies` с режимом максимизации качества на контрольных данных.

Дополнительно для каждого базового обучения выполняется дополнительное обучение *только* головы оракула (соответствующий запуск описан тем же кодовым деревом экспериментов); после этого перебор по решётке правил повторяется на тех же данных контроля, что исключает смещение сравнения из-за другой контрольной выборки.

Сводку по языковому моделированию на WikiText-103 см. разд. 10. Серия на ARC-AGI и перебор по решётке стратегий с этапом донастройки головы оракула — разд. 11. Эмпирические распределения оракульного $\tau^\star$ для ветки `finite_discrete` на контроле приводятся в обоих результатных разделах.

10 Результаты языкового моделирования на WikiText-103

Под корпусом WikiText-103 [18] выбрана та же связка конфигураций семейства распределения времени, правила остановки на контроле и критерия отбора, что описана для ARC-AGI в разд. 9.4; здесь объект прогноза — следующий токен, а качество задаётся долей топ-1 по кандидатам выходного словаря после остановки. Во всех строчках ниже численные столбцы согласованы с промежуточным протоколом оценки (контрольная доля задачи языкового моделирования, $K{=}8$).

10.1 Эмпирическое распределение оракульного $\tau^\star$

На рис. 3 приведено эмпирическое распределение индекса шага $\tau^\star \in \{1, \ldots, K\}$, на котором достигается максимум пакетно агрегированной токеновой точности по внутренним шагам, для варианта «`finite_discrete`» после базового прохода обучения. Как и для решёточных задач ARC-AGI, заметная доля массы приходится на малые значения $\tau^\star$: для многих пакетов хватает одного–двух внутренних шагов, однако остаётся и перераспределение на промежуточные индексы.

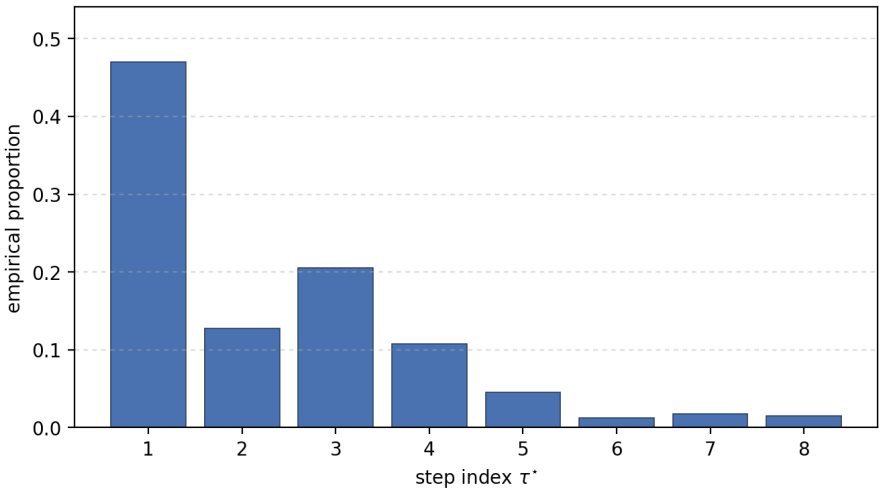

Рис. 3. Распределение $\tau^\star$ по номеру шага (топ-1 точность следующего токена). WikiText-103, `finite_discrete`, $K{=}8$.

10.2 Сводка по семействам распределений (базовое обучение)

Табл. 6 устроена аналогично табл. 8: по одному семейству — одна строка после выбора лучшей связки правила на контроле среди результатов решётки. Имена полей и смысл столбцов совпадают с разделом результатов ARC-AGI, поэтому прикладной интерпретатор

столбца $\mathrm{tok}_{\mathrm{best}}$ здесь понимает топ-1 на языковых позициях.

Таблица 6. WikiText-103 (контрольная выборка): лучшая по решётке комбинация правила после базового обучения.

Семейство (ключ)	Стратегия (ключ)	Порог	$\bar{\tau}$	Потери к оракулу	$\mathrm{tok}_{\mathrm{best}}$	NLL_{τ}
`finite_discrete`	`cumulative_probability`	0,85	3,12	0,0064	0,331	1,068
`smoothed_loss`	`cumulative_probability`	0,6	8,00	0,0081	0,326	2,058
`mixture_geometric`	`cumulative_probability`	0,85	4,02	0,0093	0,339	0,988
`mixture_exponential`	`cumulative_probability`	0,75	3,54	0,0136	0,336	1,062
`power`	`cumulative_probability`	0,75	3,66	0,0251	0,334	1,089
`negative_binomial`	`cumulative_probability`	0,9	3,74	0,0087	0,328	1,274

Абсолютные значения $\mathrm{tok}_{\mathrm{best}}$ умеренны относительно крупных открытых языковых систем: постановка использует малую рекурсивную сборку над замороженным эмбеддером и ограниченный ресурс обучения, поэтому сравнимость рядом в таблице важнее абсолютного уровня.

10.3 Влияние дополнительного обучения только головы оракула

Табл. 7 повторяет логику табл. 9: на контроле заново подбирается режим правила для базового чекпоинта и для версии после донастройки только головы оракула.

Таблица 7. Сравнение базового обучения и дополнительного обучения головы оракула (WikiText-103).

Семейство (*ключ*)	Стратегия / порог связка на контроле		$\mathrm{tok}_{\mathrm{best}}$		$\bar{\tau}$	
	до	после гол. орак.	до	после	до	после
`finite_discrete`	cum./0.85	haz./0.5	0,331	0,333	3,12	1,79
`smoothed_loss`	cum./0.6	cum./0.6	0,326	0,326	8,00	8,00
`mixture_geometric`	cum./0.85	cum./0.58	0,339	0,338	4,02	1,71
`mixture_exponential`	cum./0.75	haz./0.5	0,336	0,335	3,54	3,51
`power`	cum./0.75	cum./0.62	0,334	0,333	3,66	1,94
`negative_binomial`	cum./0.9	cum./0.62	0,328	0,324	3,74	2,41

Для `smoothed_loss` оптимальная строка на контроле сохраняется; для нескольких гладких по параметрам семейств перенастройка головы смещает режим стопора к более короткой глубине при почти неизменном качестве, а семейство `negative_binomial` снова демонстрирует более чувствительное снижение $\mathrm{tok}_{\mathrm{best}}$.

10.4 Кривая качество–стоимость

Рисунок 4 задаёт точечное представление задачи качество–глубина в тех же координатах, что и для ARC (таблица результатов здесь служит источником координат).

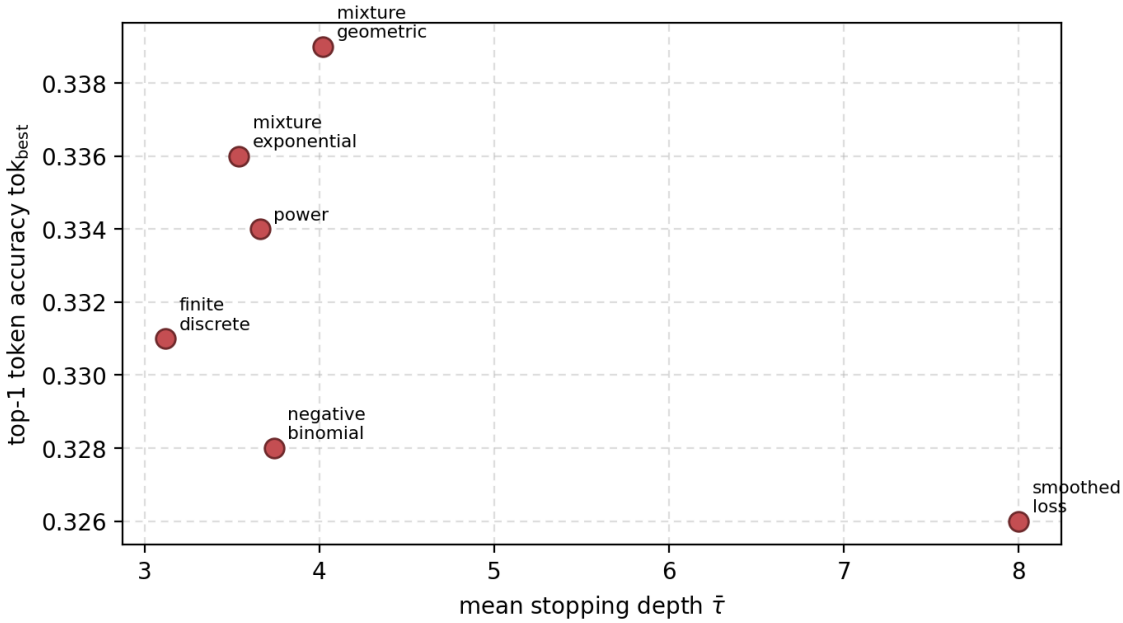

Рис. 4. Среднее число шагов и топ-1 точность по табл. 6 (WikiText-103, базовое обучение).

Выделяются три недоминируемые точки: `finite_discrete` с минимальным средним числом шагов $\bar{\tau}\approx 3{,}12$ и tok$_{\text{best}}\approx 0{,}331$; семейство `mixture_exponential` как компромисс $\bar{\tau}\approx 3{,}54$ и tok$_{\text{best}}\approx 0{,}336$; `mixture_geometric` с лучшим среди шести вариантов tok$_{\text{best}}\approx 0{,}339$ при $\bar{\tau}\approx 4{,}02$. Относительно этой тройки семейство `smoothed_loss` задаёт режим $\bar{\tau}=K$ без экономии расчётов при самой низкой в таблице точности $\approx 0{,}326$; остальные строки доминируются промежуточным решением или максимальной точкой в паретовском наборе.

11 Результаты на ARC-AGI

11.1 Эмпирическое распределение оракульного $\tau^\star$

На рис. 5 показано эмпирическое распределение индекса шага $\tau^\star \in \{1, \ldots, K\}$, на котором достигается максимум *пакетно агрегированной* токеновой точности по цепочке внутренних шагов (аргумент максимума по шагам надзора, $K{=}8$; контрольный прогон для варианта «`finite_discrete`»). То есть для каждого пакета примеров строится кривая точности против номера шага, затем $\tau^\star$ — номер её максимума; столбики на графике задают доли пакетов, для которых максимум пришёлся на указанном шаге. Доля около $\tau^\star{=}1$ доминирует, но заметная масса попадает и на несколько более поздних шагов — однородный запуск на полную глубину смешивает простые и сложные примеры.

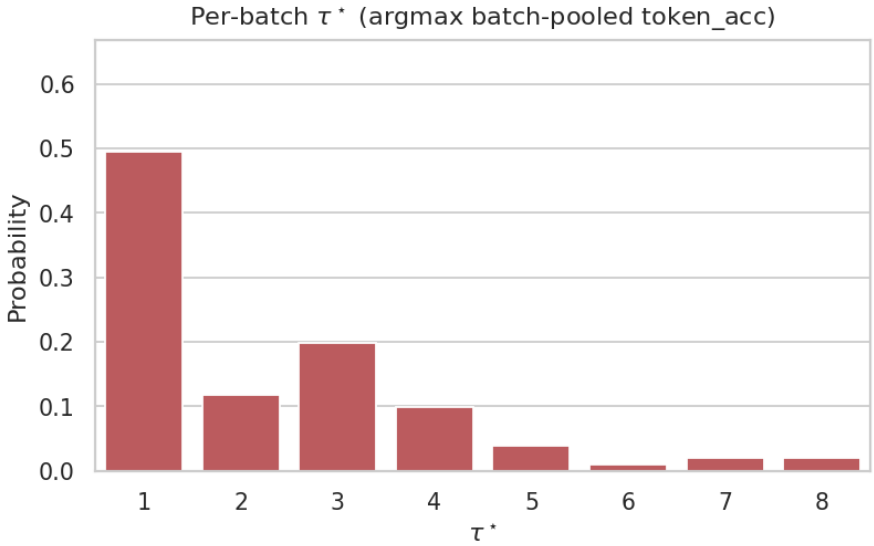

Рис. 5. Распределение $\tau^\star$ по шагам (потокенная точность). ARC-AGI, ветка `finite_discrete`, $K{=}8$.

11.2 Сводка по семействам распределений (базовое обучение)

Ниже (табл. 8) каждая **строка соответствует одному семейству распределений** момента остановки после базового обучения (название в первом столбце — имя конфигурации в серии экспериментов). Для каждого семейства по полной решётке стратегий остановки и порогам выбирается одна строка, дающая максимум токеновому качеству по лучшему среди интервалов кандидатов ответов (интегральный критерий отбора в протоколе оценки остановки). В таблице явно сохранены

программные имена строк для семейства и стратегии; числовые поля переведены ниже на русские термины.

Столбцы. *Порог* — параметр используемого правила (число; здесь всюду стратегия накопленной вероятности). $\bar{\tau}$ — среднее фактически выполненное число внутренних шагов при выбранном правиле. *Потери к оракулу* — среднее отклонение суммарного риска относительно оракульного выбора (постфактум, сводная величина в протоколе оценки). $\mathrm{tok}_{\mathrm{best}}$ — достигнутое токеновое качество в точке остановки по лучшей из рассматриваемых гипотез ответа. NLL_{τ} — отрицательная логарифмическая потеря в момент остановки.

Таблица 8. ARC-AGI (контрольная выборка): лучшая по решётке комбинация правила после базового обучения.

Семейство (ключ)	Стратегия (ключ)	Порог	$\bar{\tau}$	Потери к оракулу	$\mathrm{tok}_{\mathrm{best}}$	NLL_{τ}
`finite_discrete`	`cumulative_probability`	0,9	3,44	0,004 29	0,730	1,126
`smoothed_loss`	`cumulative_probability`	0,6	5,00	0,004 92	0,737	2,015
`mixture_geometric`	`cumulative_probability`	0,9	4,25	0,007 28	0,745	0,974
`mixture_exponential`	`cumulative_probability`	0,8	3,50	0,012 17	0,742	1,099
`power`	`cumulative_probability`	0,8	3,71	0,021 38	0,741	1,125
`negative_binomial`	`cumulative_probability`	0,9	3,85	0,007 12	0,731	1,271

Доля полностью точных решёток ARC на уровне токена близка к нулю, что типично для пошаговой разметки на сложных задачах.

11.3 Влияние дополнительного обучения только головы оракула

Табл. 9 сохраняет ту же связку столбцов для метрик качества $\mathrm{tok}_{\mathrm{best}}$ и $\bar{\tau}$, но сравнивает *до* и *после* дополнительного обучения только головы оракула. В блоке «режим и порог» указаны связки «стратегия / порог», найденные по контрольной выборке отдельно для базовой и донастроенной сохранённой модели (повторный подбор на той же решётке).

Таблица 9. Сравнение базового обучения и дополнительного обучения головы оракула (ARC-AGI). В столбцах метрик «после” — сохранённая модель после донастройки только головы оракула (подбор стратегии и порога на контрольной выборке, как до).

Семейство (*ключ*)	Стратегия / порог связка на контроле		$\mathrm{tok}_{\mathrm{best}}$		$\bar{\tau}$	
	до	после гол. орак.	до	после	до	после
finite_discrete	cum./0.9	haz./0.5	0,730	0,732	3,44	1,98
smoothed_loss	cum./0.6	cum./0.6	0,737	0,737	5,00	5,00
mixture_geometric	cum./0.9	cum./0.6	0,745	0,744	4,25	1,74
mixture_exponential	cum./0.8	haz./0.5	0,742	0,741	3,50	3,44
power	cum./0.8	cum./0.6	0,741	0,740	3,71	1,87
negative_binomial	cum./0.9	cum./0.6	0,731	0,727	3,85	2,35

Для smoothed_loss дополнительное обучение головы не меняет оптимальную строку сводки. Для finite_discrete, mixture_geometric и power оптимальное правило смещается в сторону более агрессивной ранней остановки (hazard или меньший порог cumulative_probability), при этом $\mathrm{tok}_{\mathrm{best}}$ меняется незначительно. Для negative_binomial наблюдается небольшое снижение $\mathrm{tok}_{\mathrm{best}}$ после донастройки головы; интерпретация этого факта обсуждается в разд. 12.

11.4 Кривая качество–стоимость

Полное семейство кривых «качество–среднее число шагов» при изменении каждого порога по всей решётке здесь не приводится (это многомерный объект). На рис. 6 показано согласованное с табл. 8 сечение задачи качество–стоимость в шести точках (по одной на семейство): абсцисса — $\bar{\tau}$ после перебора, ордината — $\mathrm{tok}_{\mathrm{best}}$.

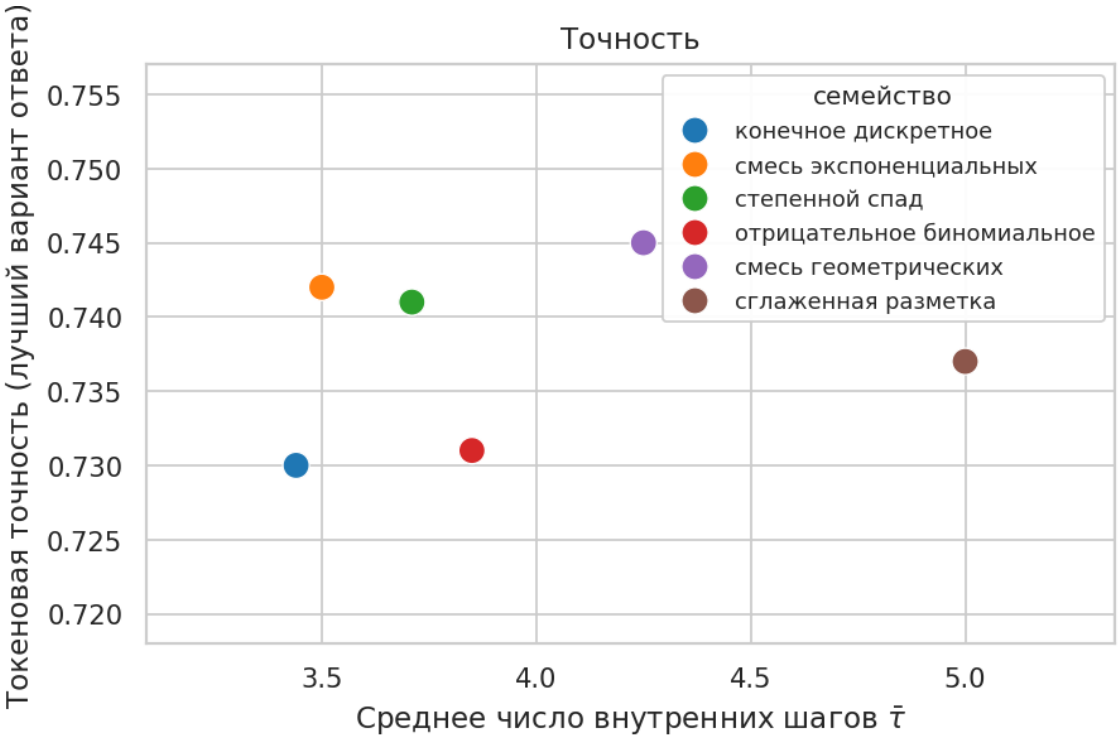

Рис. 6. Среднее число шагов и токеновая точность по табл. 8 (контроль, ARC-AGI, базовое обучение).

Интерпретируя рис. 6 как набор вариантов с двумя целями — повысить $\mathrm{tok}_{\mathrm{best}}$ и уменьшить $\bar{\tau}$ при фиксированном протоколе перебора — можно выделить паретовский поднабор недоминируемых решений. Одна точка не хуже другой только если у неё не больше среднее число шагов *и* не ниже $\mathrm{tok}_{\mathrm{best}}$, причём хотя бы одно из неравенств строгое. В указанном сечении недоминируемы три семейства: `finite_discrete` (минимальное $\bar{\tau} \approx 3{,}44$ при наименьшей среди них точности $\approx 0{,}73$); `mixture_exponential` (компромисс $\bar{\tau} \approx 3{,}50$, $\mathrm{tok}_{\mathrm{best}} \approx 0{,}74$); `mixture_geometric` (максимум $\mathrm{tok}_{\mathrm{best}} \approx 0{,}75$ при наибольшем $\bar{\tau} \approx 4{,}25$ среди тройки). Точки `power`, `negative_binomial` и `smoothed_loss` доминируются семейством `mixture_exponential` или `mixture_geometric` в указанном смысле: для них есть вариант одновременно с меньшим $\bar{\tau}$ и с не меньшей токеновой точностью по числам табл. 8.

12 Обсуждение

12.1 Интерпретация свода ARC-AGI

Лучшие по сетке строки для базового обучения (табл. 8) показывают, что наибольшая токеновая точность при выборе между режимами ответа `last` и `argmax_interval` достигается у `mixture_geometric` при умеренном среднем числе шагов $\bar{\tau} \approx 4{,}25$. Семейство `smoothed_loss` достигает сравнимой точности при $\bar{\tau} = K$, то есть фактически без экономии глубины в выбранной оптимальной строке сводки. Семейство `power` даёт конкурентоспособную точность, но с бóльшими потерями по сравнению с оракульным выбором, что согласуется с менее жёсткой параметризацией хвоста: ошибка распределения времени дороже в смысле (10).

12.2 Дополнительное обучение только головы оракула и сдвиг распределений

Дополнительное обучение только головы оракула при замороженной рекурсивной части меняет не столько предельную токеновую точность при полном прогоне, сколько совместную конфигурацию «распределение $\to$ правило остановки». В табл. 9 видно, что для ряда семейств оптимальная стратегия после донастройки сохранённой модели смещается к более ранней остановке при почти неизменной $\mathrm{tok}_{\mathrm{best}}$. Это можно интерпретировать как смещение соответствия предсказанных масс $\widehat{p}_{t,k}$ эмпирическому распределению остаточных ошибок на контрольной выборке: правило `hazard` становится конкурентоспособным, когда отношение $\widehat{p}_{t,k}(k)/\sum_{j\geq k}\widehat{p}_{t,k}(j)$ лучше согласовано с фактическими условными частотами.

Сдвиг распределения $\tau^\star$ между обучением и контролем в строгом смысле требует сравнения двух эмпирических распределений на $\{0,\ldots,K\}$, построенных по независимым наборам задач (обучающий набор и контрольный набор). В данной версии эксперимента параллельная гистограмма $\tau^\star$ для данных обучения явно не фиксируется; качественное расхождение режимов проявляется в различии кривых токеновой точности по шагам на обучении и контроле и в изменении оптимальной строки сводки после дополнительного обучения оракула. Наблюдаемое для `negative_binomial` ухудшение $\mathrm{tok}_{\mathrm{best}}$ после донастройки согласуется с гипотезой локального переобучения головы на обучающих метках $\tau^\star$,

не совпадающих с режимом сложности на контроле; это *гипотеза*, а не следствие теоремы, и проверяется дополнительными регуляризаторами или ранней остановкой этапа донастройки.

12.3 Связь с постановкой математической статистики

С позиций теории решений [10] оракул (10) задает нижнюю границу риска при полной информации, а практическое правило (37) — это $\mathcal{H}_{t,k}$-измеримая аппроксимация, чей риск раскладывается на ошибку прогноза $\tau^\star$ и ошибку остановки по глубине. Разделение оценки полного закона и решающей функции позволяет отдельно анализировать чувствительность к сдвигу распределения при смене выборки (например, при переходе от обучения к контролю).

13 Заключение

В работе сформулирована вероятностная постановка задачи выбора времени остановки при рекурсивном прогнозировании речи. Речь рассматривается как случайная последовательность на конечном словаре, а рекурсивная модель строит несколько последовательных распределений следующей языковой единицы. По полной последовательности потерь определяется оракульное время остановки, минимизирующее сумму ошибки и стоимости вычислений.

Основная статистическая задача состоит в оценке условного распределения этого оракульного времени по информации, доступной на текущем внутреннем шаге. Правило остановки отделено от модели распределения. Это позволяет учитывать не только вероятность остановки сейчас, но и вероятность того, что оптимальный момент уже был в прошлом или еще находится впереди.

Рассмотрены шесть семейств распределений на $\{0, \ldots, K\}$: конечное дискретное, сглаженная целевая разметка по потерям, смесь геометрических, дискретизированная смесь экспоненциальных, степенной спад на отрезке и отрицательное биномиальное распределение. Для принятия решения используются пять правил: накопленная вероятность, малая вероятность будущего улучшения, условная интенсивность по предсказанной мере, квантиль и бюджетное правило.

На данных WikiText-103 и ARC-AGI приведены согласованные по протоколу контрольные сводки: перебор стратегий остановки, эмпирическое распределение оракульного $\tau^\star$ для варианта `finite_discrete` и сравнение базового обучения с дополнительным обучением только головы оракула.

Направления дальнейшей работы: (i) полный языковой перебор по той же схеме оценки; (ii) формальные оценки смещения эмпирического распределения $\tau^\star$ при переходе от обучающей выборки к контрольной; (iii) постановка вероятностных гарантий устойчивости выбранного правила остановки при смене выборки (в том числе при разных разбиениях на обучение и контроль).

Список литературы

[1] ARC Prize Foundation. *ARC-AGI Benchmark*. `https://arcprize.org/arc-agi`. Электронный ресурс. 2024.

[2] D. Bahdanau, K. Cho и Y. Bengio. “Neural Machine Translation by Jointly Learning to Align and Translate”. В: *International Conference on Learning Representations*. 2015.

[3] D. P. Bertsekas. *Dynamic Programming and Optimal Control*. 3rd. Т. 1. Belmont, MA: Athena Scientific, 2005.

[4] C. M. Bishop. *Pattern Recognition and Machine Learning*. Springer, 2006.

[5] T. Brown и др. “Language Models are Few-Shot Learners”. В: *Advances in Neural Information Processing Systems*. Т. 33. 2020, с. 1877—1901.

[6] F. Chollet. *On the Measure of Intelligence*. 2019. arXiv: `1911.01547`.

[7] J. Devlin, M.-W. Chang, K. Lee и K. Toutanova. “BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding”. В: *Proceedings of the 2019 Conference of the North American Chapter of the ACL*. 2019, с. 4171—4186.

[8] A. Dosovitskiy и др. “An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale”. В: *International Conference on Learning Representations*. 2021.

[9] M. Elbayad, J. Gu, E. Grave и M. Auli. “Depth-Adaptive Transformer”. В: *International Conference on Learning Representations*. 2020.

[10] T. S. Ferguson. *Mathematical Statistics: A Decision Theoretic Approach*. Academic Press, 1967.

[11] I. Goodfellow, Y. Bengio и A. Courville. *Deep Learning*. Cambridge, MA: MIT Press, 2016.

[12] A. Graves. *Adaptive Computation Time for Recurrent Neural Networks*. 2016. arXiv: `1603.08983`.

[13] S. Hochreiter и J. Schmidhuber. “Long Short-Term Memory”. В: *Neural Computation* 9.8 (1997), с. 1735—1780.

[14] R. A. Howard. *Dynamic Programming and Markov Processes*. Cambridge, MA: MIT Press, 1960.

[15] E. J. Hu и др. *LoRA: Low-Rank Adaptation of Large Language Models*. 2021. arXiv: `2106.09685`.

[16] A. Jolicoeur-Martineau. *Less Is More: Recursive Reasoning With Tiny Networks*. 2025. arXiv: `2510.04871 [cs.LG]`.

[17] D. P. Kingma и J. Ba. “Adam: A Method for Stochastic Optimization”. В: *International Conference on Learning Representations*. 2015.

[18] S. Merity и др. “Pointer Sentinel Mixture Models”. В: *arXiv preprint arXiv:1609.07843* (2016).

[19] T. Mikolov, K. Chen, G. Corrado и J. Dean. “Efficient Estimation of Word Representations in Vector Space”. В: *International Conference on Learning Representations*. 2013.

[20] G. Peskir и A. N. Shiryaev. *Optimal Stopping and Free-Boundary Problems*. Basel: Birkhäuser, 2006.

[21] A. Radford, J. Wu, R. Child, D. Luan, D. Amodei и I. Sutskever. *Language Models are Unsupervised Multitask Learners*. Тех. отч. техотчёт GPT-2. OpenAI, 2019.

[22] H. Robbins. “A sequential decision problem with a finite memory”. В: *Proceedings of the National Academy of Sciences* 42 (1956), с. 920—923.

[23] J. L. Snell. “Applications of martingale system theorems”. В: *Transactions of the American Mathematical Society* 73.2 (1952), с. 293—312.

[24] I. Sutskever, O. Vinyals и Q. V. Le. “Sequence to Sequence Learning with Neural Networks”. В: *Advances in Neural Information Processing Systems*. Т. 27. 2014.

[25] R. S. Sutton и A. G. Barto. *Reinforcement Learning: An Introduction*. 2nd. Cambridge, MA: MIT Press, 2018.

[26] S. Teerapittayanon, B. McDanel и H. T. Kung. “BranchyNet: Fast Inference via Early Exiting from Deep Neural Networks”. В: *International Conference on Pattern Recognition*. 2016, с. 2464—2469.

[27] A. Vaswani и др. “Attention Is All You Need”. В: *Advances in Neural Information Processing Systems*. Т. 30. 2017.

[28] A. Wald. *Sequential Analysis*. New York: John Wiley и Sons, 1947.

[29] J. Xin и др. “DeeBERT: Dynamic Early Exiting for Accelerating BERT Inference”. В: *Proceedings of the 58th Annual Meeting of the ACL*. 2020, с. 2835—2840.

[30] А. Н. Ширяев. *Вероятность*. Москва: МЦНМО, 2007.